数据科学与大数据技术（Data Science and Big Data Technology）

一、学科体系与核心任务

- 1. 学科定位与概念层级
  - 数据科学（Data Science）：以数据为对象，融合统计推断、计算技术与领域知识，提取可行动洞见
  - 大数据技术（Big Data Technology）：支撑海量数据采集、存储、计算、治理与服务的工程体系
  - 二者关系：数据科学是方法论层，大数据技术是工程底座；构成「分析 — 工程」双轮
  - 三支柱模型（Conway Venn）：数学与统计、计算机科学、领域知识
  - 学科边界
    - 统计学：重推断与因果，关注样本代表性与不确定性
    - 计算机科学：重系统与算法，关注可扩展性与正确性
    - 机器学习：重预测性能，弱化可解释性
    - 数据工程：重管道可靠性与数据时效
  - 一句话区分：统计关心「为什么」，机器学习关心「准不准」，数据工程关心「跑不跑得动」
- 2. 分析层次（Analytics Hierarchy）
  - 描述性分析（Descriptive）：发生了什么 —— 报表、看板、聚合统计
  - 诊断性分析（Diagnostic）：为什么发生 —— 下钻、归因、相关分析
  - 预测性分析（Predictive）：会发生什么 —— 回归、分类、时间序列
  - 规范性分析（Prescriptive）：应该怎么做 —— 优化求解、决策建议、实验
  - 成熟度演进：报表 → 洞察 → 预测 → 决策自动化
  - 认知型分析（Cognitive）：自然语言问答、自动洞察生成
- 3. 标准流程（CRISP-DM）
  - 业务理解（Business Understanding）：目标定义、成功标准、资源约束
  - 数据理解（Data Understanding）：数据探查、质量初判、分布画像
  - 数据准备（Data Preparation）：清洗、集成、变换、规约、构造
  - 建模（Modeling）：算法选择、训练、调参、集成
  - 评估（Evaluation）：离线指标、业务校验、可行性复核
  - 部署（Deployment）：上线、监控、迭代、回流
  - 其他流程：KDD、SEMMA、TDSP（微软团队数据科学流程）
- 4. 核心任务类型
  - 探索性数据分析（EDA）：分布、相关性、异常、分组对比
  - 统计推断与假设检验
  - 回归与分类预测
  - 聚类与用户分群
  - 时间序列预测
  - 推荐与排序
  - 因果推断与实验评估
  - 异常检测与风控
  - 文本、图像、图数据分析
  - 数据可视化与叙事
- 5. 大数据特征（5V）
  - Volume 体量：TB → PB → EB 级
  - Velocity 速度：批处理（Batch）vs 流处理（Streaming）vs 实时（Real-time）
  - Variety 多样性：结构化、半结构化、非结构化
  - Veracity 真实性：噪声、缺失、偏差、口径不一致
  - Value 价值：价值密度低，需加工提炼
  - 补充维度：Variability 可变性、Visualization 可视化

二、方法与技术体系

- 1. 统计学基础
  - 1.1 描述统计
    - 集中趋势：均值、中位数、众数、截尾均值
    - 离散程度：方差、标准差、极差、四分位距 IQR、变异系数
    - 分布形态：偏度（Skewness）、峰度（Kurtosis）
    - 分位数与箱线图
    - 相关性：Pearson（线性）、Spearman（秩）、Kendall、互信息
    - 可视化诊断：直方图、QQ 图、散点矩阵
  - 1.2 推断统计
    - 抽样方法：简单随机、分层、整群、系统抽样
    - 抽样分布与中心极限定理
    - 参数估计：点估计、矩估计、极大似然估计 MLE
    - 区间估计：置信区间、Bootstrap 重采样
    - 假设检验：原假设与备择假设、显著性水平 α、p 值
    - 常用检验：单样本/双样本 t 检验、卡方检验、方差分析 ANOVA、非参数检验（Mann-Whitney、Wilcoxon）
    - 两类错误：第一类（弃真）、第二类（取伪）、统计功效 Power
    - 多重比较校正：Bonferroni、Benjamini-Hochberg FDR
    - p 值的常见误读：不是「原假设为真的概率」
  - 1.3 回归建模
    - 简单线性回归、多元线性回归
    - 最小二乘估计、正规方程、梯度下降
    - 广义线性模型 GLM：逻辑回归、泊松回归、负二项回归
    - 正则化：Ridge（L2）、Lasso（L1）、ElasticNet
    - 模型诊断：残差分析、异方差、共线性 VIF、影响点 Cook 距离
    - 变量选择：逐步回归、AIC/BIC、交叉验证
    - 交互项与非线性变换
  - 1.4 时间序列
    - 基础概念：趋势、季节、周期、随机项
    - 平稳性检验：ADF、KPSS；差分与对数变换
    - 自相关：ACF、PACF
    - 经典模型：AR、MA、ARMA、ARIMA、SARIMA、SARIMAX
    - 指数平滑：简单、Holt、Holt-Winters
    - 状态空间模型与卡尔曼滤波
    - Prophet：趋势 + 季节 + 节假日
    - 深度方法：LSTM、TCN、Transformer、N-BEATS、DeepAR
    - 评估：MAE、RMSE、MAPE、sMAPE、滚动回测
  - 1.5 因果推断
    - 潜在结果框架（Rubin Causal Model）、反事实
    - 随机对照试验 RCT、A/B 测试
    - 观察性研究方法
      - 倾向得分匹配 PSM、逆概率加权 IPW
      - 双重差分 DID、三重差分 DDD
      - 断点回归 RDD
      - 工具变量 IV、两阶段最小二乘
      - 合成控制法 SCM
    - 因果图 DAG：混杂因子、对撞因子、中介因子
    - 中介效应与调节效应
    - 因果发现：PC 算法、LiNGAM
  - 1.6 贝叶斯方法
    - 先验、似然、后验、贝叶斯公式
    - 共轭先验、Beta-Binomial、正态-正态
    - 计算方法：MCMC（Gibbs、Metropolis-Hastings）、变分推断 VI
    - 层次贝叶斯模型
    - 贝叶斯 A/B 测试与决策
- 2. 机器学习与建模
  - 学习范式：监督、无监督、半监督、自监督、强化学习
  - 常用算法
    - 线性与逻辑回归、决策树、随机森林、GBDT、XGBoost、LightGBM
    - SVM、KNN、朴素贝叶斯
    - 聚类：K-means、DBSCAN、GMM、层次聚类
    - 降维：PCA、t-SNE、UMAP
  - 特征工程
    - 缺失值处理、异常值处理、截断变换
    - 编码：独热、标签、目标编码、WOE
    - 归一化与标准化：Min-Max、Z-Score、Robust
    - 分箱、交叉特征、聚合特征、时间窗口特征
    - 特征选择：过滤式、包裹式、嵌入式
  - 模型训练与选择
    - 数据划分、交叉验证、时间序列切分
    - 过拟合与正则化、早停
    - 超参搜索：网格、随机、贝叶斯优化（Optuna）
    - 集成策略：Bagging、Boosting、Stacking、Blending
  - 模型评估与解释
    - 分类：Acc、P、R、F1、ROC-AUC、PR-AUC、KS、Lift
    - 回归：MSE、RMSE、MAE、R²、MAPE
    - 可解释性：特征重要性、SHAP、LIME、PDP、ICE
  - 类别不平衡：重采样（SMOTE）、代价敏感、阈值调优、EasyEnsemble
  - 自动化机器学习（AutoML）：自动特征工程、NAS、超参优化、模型集成
  - 模型风险：稳定性、公平性、漂移、可复现性
- 3. 大数据技术栈
  - 3.1 存储层
    - 分布式文件系统：HDFS（NameNode / DataNode、块副本、机架感知）
    - NoSQL
      - HBase：LSM-Tree、RowKey 设计、Region 分裂
      - Cassandra、MongoDB、Redis（缓存与计数）
    - 对象存储：AWS S3、阿里 OSS、MinIO
    - 列式存储格式：Parquet、ORC、Avro；压缩：Snappy、Zstd、Gzip
    - 数据湖表格式：Delta Lake、Apache Iceberg、Apache Hudi（ACID、时间旅行、增量读）
  - 3.2 计算层
    - 批处理
      - MapReduce：已边缘化，理解思想即可
      - Spark：RDD、DataFrame、Dataset、Spark SQL、Catalyst 优化器、Tungsten、Shuffle 机制
      - Spark 调优：分区、广播、缓存、数据倾斜处理
    - 流处理
      - Flink：事件时间、水位线（Watermark）、窗口、状态管理、Checkpoint、Exactly-Once
      - Spark Structured Streaming、Kafka Streams、Storm
    - 流批一体：Flink、Spark 3.x、Kappa 架构
    - 交互式查询：Presto / Trino、Impala、Dremio
    - OLAP 引擎：ClickHouse、Apache Doris、StarRocks、Druid、Kylin
    - 资源调度：YARN、Kubernetes、Mesos
    - 计算模型对比：批 vs 流 vs 湖仓一体
  - 3.3 采集与集成
    - 日志采集：Flume、Filebeat、Logstash、Fluentd
    - 数据库同步：Sqoop（批量）、Canal / Debezium（CDC 增量）、DataX
    - 消息中间件：Kafka（分区、副本、消费组）、Pulsar、RabbitMQ
    - ETL vs ELT：传统抽取转换加载 vs 先入湖再计算
    - 数据集成模式：联邦查询、物化视图、实时同步
  - 3.4 数据仓库与建模
    - 架构演进：Inmon 企业级数仓 → Kimball 维度建模 → 数据湖 → 湖仓一体
    - 分层架构：ODS → DWD → DWS → ADS（辅以 DIM 公共维表）
    - 维度建模
      - 事实表：事务型、周期快照、累积快照
      - 维度表：星型模型、雪花模型、星座模型
      - 代理键、退化维、杂项维、一致性维度
    - 缓慢变化维 SCD：Type 1（覆盖）、Type 2（拉链）、Type 3（新增列）
    - 拉链表、全量表、增量表、快照表
    - 指标体系：原子指标、派生指标、复合指标；指标口径管理
    - 数据建模工具：PowerDesigner、ERWin、dbt
  - 3.5 数据治理
    - 元数据管理：Apache Atlas、DataHub、Amundsen、自建资产目录
    - 数据血缘（Lineage）与影响分析
    - 数据质量：完整性、准确性、一致性、及时性、唯一性、有效性
    - 质量工具：Great Expectations、Deequ、规则引擎 + 告警
    - 主数据管理 MDM、数据标准、数据字典、命名规范
    - 数据安全：分级分类、脱敏、加密、水印、权限模型（RBAC / ABAC）
    - 合规：GDPR、个人信息保护法、数据出境评估
    - 成本治理：存储生命周期、冷热分层、计算资源配额
  - 3.6 可视化与 BI
    - 工具：Tableau、Power BI、Apache Superset、Metabase、FineBI、ECharts
    - 图表选型：比较（柱状）、趋势（折线）、构成（饼图/堆叠）、分布（直方/箱线）、关系（散点/网络）
    - 看板设计：指标卡、下钻、联动、筛选器、移动端适配
    - 数据叙事（Data Storytelling）：结论先行、对比锚定、视觉层级
    - 自助分析：语义层、指标平台、即席查询
- 4. 编程与查询
  - Python：Pandas、NumPy、Polars、PySpark、scikit-learn、statsmodels
  - R：tidyverse、ggplot2、caret
  - SQL：DDL / DML、多表 JOIN、窗口函数、CTE、子查询、执行计划、索引与分区优化
  - Scala / Java：Spark、Flink 作业开发
  - Shell / Linux：命令行、cron 调度、日志排查
  - 环境与协作：Jupyter、Git、虚拟环境、Docker
- 5. 指标体系与分析框架
  - 北极星指标（North Star Metric）与一级指标拆解
  - AARRR 模型：获取、激活、留存、变现、推荐
  - 漏斗分析（Funnel）与转化率优化
  - 同期群分析（Cohort）与留存曲线
  - 用户分层：RFM、价值分层、行为分群
  - 归因模型：首次、末次、线性、时间衰减、Shapley
  - 用户画像与标签体系：事实标签、模型标签、规则标签
  - 实验体系：分流、AA 测试、样本量计算、显著性判定、实验平台
- 6. 数据挖掘与高级分析
  - 关联规则挖掘
    - 经典算法：Apriori、FP-Growth、Eclat
    - 评价指标：支持度、置信度、提升度、杠杆率、确信度
    - 典型应用：购物篮分析、交叉销售、套餐组合、货架关联
  - 序列与模式挖掘
    - 序列模式：PrefixSpan、SPADE、GSP
    - 频繁子图：gSpan、CloseGraph
    - 应用：用户行为路径、点击流、故障序列
  - 图分析
    - 中心性：度中心性、介数中心性、接近中心性、特征向量中心性
    - 社区发现：Louvain、Leiden、标签传播、谱聚类
    - 其他：链路预测、影响力最大化、图嵌入（Node2Vec、DeepWalk）
  - 文本分析
    - 预处理：分词、去停用词、词干化、正则清洗
    - 表示：Bag-of-Words、TF-IDF、Word2Vec、BERT Embedding
    - 主题模型：LDA、NMF
    - 任务：情感分析、文本分类、聚类、命名实体识别、关键词抽取
  - 向量表示与检索
    - 向量数据库：Milvus、Qdrant、Weaviate、pgvector
    - 近似最近邻索引：HNSW、IVF-PQ、LSH
    - 评价：Recall@K、QPS、P99 延迟
  - 时间序列异常检测：STL 分解残差法、矩阵剖面（Matrix Profile）、Prophet 残差监控
  - 半结构化与非结构化处理：JSON 展开、日志解析（正则/Grok）、图文多模态
- 7. 隐私计算与数据安全
  - 数据脱敏：掩码、泛化、假名化、抑制、置换
  - 匿名化模型：k-匿名、l-多样性、t-接近性
  - 差分隐私（Differential Privacy）：ε-差分隐私、拉普拉斯机制、高斯机制、隐私预算分配
  - 联邦学习（Federated Learning）
    - 类型：横向联邦、纵向联邦、联邦迁移
    - 聚合算法：FedAvg、FedProx
    - 风险：梯度反演、成员推断攻击
  - 安全多方计算 MPC、可信执行环境 TEE、同态加密 HE
  - 数据水印与溯源、访问控制（行列级权限）、操作审计日志

三、数据资源与评估

- 1. 数据来源与类型
  - 数据来源：业务系统、埋点日志、爬虫、第三方采购、公开数据集、传感器与 IoT
  - 数据形态：结构化（关系表）、半结构化（JSON / XML / 日志）、非结构化（文本 / 图像 / 音视频）
  - 数据时效：离线 T+1、准实时分钟级、实时秒级
  - 数据粒度：明细、汇总、快照
- 2. 常用公开数据集
  - 通用平台：Kaggle Datasets、UCI、AWS Open Data、天池、DataFountain
  - 入门练习：Titanic、Iris、Boston Housing、Adult、Wine Quality
  - 推荐与广告：MovieLens、Criteo CTR、Avazu、Taobao User Behavior、Amazon Reviews
  - 时间序列：M3 / M4 / M5、Rossmann Store Sales、Web Traffic
  - 图数据：Cora、CiteSeer、OGB、WikiVote
  - 中文语料：CLUE、THUCNews、微博情感数据集
  - 金融风控：Lending Club、Give Me Some Credit
- 3. 数据质量维度
  - 六大维度：完整性、准确性、一致性、及时性、唯一性、有效性
  - 缺失机制：完全随机缺失 MCAR、随机缺失 MAR、非随机缺失 MNAR
  - 缺失处理：删除、统计量填充、模型填充（KNN、MICE）、指示变量法
  - 异常值识别：3σ 法则、IQR 箱线法、Z-Score、孤立森林、DBSCAN
  - 重复与冲突：实体解析、模糊匹配、去重策略
  - 数据偏差：选择偏差、幸存者偏差、辛普森悖论、标签偏差
  - 口径一致性：同名字段跨系统语义漂移
- 4. 评估体系
  - 离线评估：留出法、交叉验证、时间序列滚动回测
  - 在线评估：A/B 测试、灰度发布、互斥层与正交层设计
  - 业务指标：GMV、转化率、留存率、DAU / MAU、ARPU、LTV / CAC
  - 统计功效：样本量、最小可检测效应 MDE、显著性水平、置信区间
  - 常见陷阱：多重比较、指标漂移、新奇效应、网络效应干扰、发布延迟
  - 模型监控：PSI、KS、特征分布漂移、预测偏移
- 5. 数据资产管理
  - 数据盘点与资产目录
  - 数据分级分类与密级标注
  - 数据生命周期：采集 → 存储 → 使用 → 归档 → 销毁
  - 成本优化：冷热分层、压缩编码、TTL 策略

四、应用领域

- 1. 互联网与电商
  - 用户增长、推荐系统、搜索排序、广告投放、风控反作弊、供应链预测
- 2. 金融
  - 信用评分、反欺诈、量化交易、精准营销、监管报送、资产负债管理
- 3. 电信与运营商
  - 用户流失预测、网络质量优化、位置洞察、套餐推荐
- 4. 医疗健康
  - 电子病历结构化、疾病风险预测、药物研发、医保控费、流行病监测
- 5. 政务与公共服务
  - 城市大脑、交通治理、舆情监测、一网通办、人口分析
- 6. 工业与制造
  - 设备预测性维护、质量追溯、能耗优化、排产调度、供应链协同
- 7. 交通与物流
  - 路径优化、需求预测、运力调度、冷链监控、车货匹配
- 8. 零售与快消
  - 销量预测、选品定价、门店选址、会员运营、库存周转
- 9. 内容与社交
  - 内容推荐、社交网络分析、舆情与情感分析、社区发现
- 10. 能源与环保
  - 负荷预测、碳排放核算、气象数据融合、新能源出力预测
- 11. 农业
  - 产量预测、遥感长势监测、病虫害预警、农机调度

五、工程实践与能力路径

- 1. 平台架构
  - 演进路径：单体数据库 → 数据仓库 → 数据湖 → 湖仓一体（Lakehouse）
  - Lambda 架构：批处理层 + 速度层 + 服务层（双链路）
  - Kappa 架构：纯流处理，重放历史
  - 实时数仓：Flink + Kafka + OLAP（Doris / ClickHouse）
  - 云原生数据平台：存算分离、弹性伸缩、Serverless 查询
  - 特征平台（Feature Store）：离线在线一致性、特征复用、点时间正确性
- 2. 工程实践
  - 数据管道：调度（Airflow / DolphinScheduler）、依赖管理、失败重试、幂等设计
  - 代码规范：SQL 分层与命名规范、Python 工程化、单元测试
  - 版本管理：Git、DVC 数据版本、模型版本
  - 测试：数据质量测试、管道集成测试、模型回归测试
  - 监控告警：任务延迟、数据量突增突降、空值率、分布漂移
  - 模型上线：离线批预测、在线实时推理、AB 灰度、模型监控与回滚
  - 可复现性：环境锁定、随机种子、实验记录
- 3. 能力模型
  - 统计与数学：概率统计、假设检验、回归与因果
  - 编程能力：Python、SQL、Shell
  - 数据工程：ETL、数仓建模、调度、治理
  - 机器学习：建模、评估、调优、部署
  - 业务理解：指标体系、业务拆解、问题定义
  - 表达沟通：可视化、汇报、文档撰写
- 4. 学习路径
  - 阶段 0：基础（1–2 个月）
    - Python 语法、SQL 基础、概率统计
    - 验收：能独立写出多表关联与窗口函数查询
  - 阶段 1：数据分析（2 个月）
    - Pandas、可视化、EDA、指标体系
    - 验收：完成一份完整的数据分析报告并给出可执行建议
  - 阶段 2：机器学习（2–3 个月）
    - scikit-learn、特征工程、模型评估
    - 验收：在 Kaggle 表格赛进入前 30%
  - 阶段 3：大数据技术（2–3 个月）
    - Hadoop 生态、Spark、Flink、数仓建模
    - 验收：搭建一条从采集到看板的完整链路
  - 阶段 4：项目与实习
    - 端到端项目、竞赛、实习、论文复现
- 5. 岗位与分工
  - 数据分析师 DA：指标、报表、业务分析、实验设计
  - 数据工程师 DE：采集、ETL、数仓、调度、治理
  - 数据科学家 DS：建模、因果、实验、策略
  - 机器学习工程师 MLE：模型工程化、特征平台、在线推理
  - 算法工程师：推荐、搜索、广告、风控模型
- 6. 常见认知偏差（FAQ）
  - 「数据科学 = 机器学习」：建模仅占约 20%，数据处理与业务理解占大头
  - 「大数据 = Hadoop」：技术栈已演进到 Spark / Flink / 湖仓一体
  - 「SQL 过时了」：SQL 仍是数据岗第一硬技能
  - 「模型越复杂越好」：可解释、可维护、可上线优先
  - 「数据量越大越好」：质量与代表性优先于规模
  - 「会 Python 就能做数据」：业务拆解与指标定义才是分水岭
  - 「离线跑通就能上线」：在线一致性、延迟、回滚才是工程难点
  - 「指标越多越好」：指标膨胀会导致口径混乱与决策失焦
- 7. MLOps 与数据契约
  - MLOps 闭环：数据 → 特征 → 训练 → 评估 → 部署 → 监控 → 回流
  - 数据契约（Data Contract）：schema、SLA、Owner、变更流程、破坏性变更通知
  - 特征平台（Feature Store）
    - 离线在线一致性：同一份特征定义两处计算
    - 点时间正确性（Point-in-Time Correctness）：防未来信息泄漏
    - 特征回填与版本管理
  - 模型注册：Model Registry、版本号、血缘、审批流、元数据
  - 发布策略：影子部署、A/B 测试、多臂老虎机、灰度放量
  - 漂移监控：PSI、KS、特征分布对比、概念漂移、模型衰减曲线
  - 应急机制：一键回滚、降级到规则、人工兜底
- 8. 数据伦理与合规
  - 个人信息保护：最小必要、告知同意、目的限制、可撤回
  - 数据分类分级与数据出境安全评估
  - 算法公平性：群体公平、个体公平、偏见审计与缓解
  - 可解释与可申诉：决策留痕、人工复核通道
  - 数据留存期限与销毁机制
  - 数据伦理审查：涉及人群实验的伦理边界

Presented with xmind