人工智能（Artificial Intelligence）

一、学科体系与概念层级

- 1. 概念包含关系（Taxonomy）
  - 人工智能（Artificial Intelligence, AI）：目标层，使机器具备感知、推理、学习、决策能力
  - 机器学习（Machine Learning, ML）：方法层，从数据中归纳输入到输出的映射，无需显式编程
  - 深度学习（Deep Learning, DL）：表示学习层，以多层神经网络自动学习分层特征
  - 神经网络（Neural Network, NN）：结构层，深度学习的具体模型载体
  - 包含关系：AI ⊃ ML ⊃ DL ⊃ NN
  - 边界条件
    - DL 必然使用 NN；NN 不必然构成 DL（单隐层感知机属浅层模型）
    - ML 包含大量非神经网络方法：SVM、决策树、集成学习、概率图模型
    - AI 包含非学习型方法：符号推理、搜索、规划、约束求解
  - 常见误判：将 NN 与 DL 视为同义、将 ML 与 DL 视为并列
- 2. 三大技术路线（Paradigm）
  - 符号主义（Symbolicism）
    - 核心：物理符号系统假设，知识以规则/逻辑显式表示
    - 代表：专家系统（MYCIN、DENDRAL）、知识图谱、Prolog、描述逻辑
    - 优势：可解释、可推理、小样本；局限：知识获取瓶颈、难处理感知
  - 连接主义（Connectionism）
    - 核心：以神经元连接与权重分布表示知识
    - 代表：感知机、深度学习、大模型
    - 优势：端到端、可扩展；局限：黑箱、依赖数据与算力
  - 行为主义（Actionism）
    - 核心：智能源于与环境的交互闭环
    - 代表：强化学习、控制论、具身智能、多智能体
    - 优势：序贯决策；局限：样本效率低、奖励设计困难
  - 当前主流：连接主义为主干，符号主义用于知识注入与校验，行为主义用于决策与对齐
- 3. 发展脉络（Timeline）
  - 1943 McCulloch-Pitts 神经元模型，连接主义起点
  - 1950 图灵测试（Turing Test）
  - 1956 达特茅斯会议，AI 学科确立
  - 1958 Rosenblatt 感知机（Perceptron）
  - 1966 ELIZA，首个对话程序
  - 1969 Minsky & Papert《Perceptrons》，指出单层感知机无法解异或，连接主义受挫
  - 1974–1980 第一次 AI 寒冬（算力与数据不足、预期落空）
  - 1980s 专家系统商业化（XCON），符号主义高峰
  - 1986 Rumelhart / Hinton / Williams 推广反向传播
  - 1987–1993 第二次 AI 寒冬（LISP 机市场崩溃）
  - 1995 Cortes & Vapnik 提出软间隔 SVM
  - 1997 IBM 深蓝战胜卡斯帕罗夫
  - 2001 Breiman 随机森林；统计学习成为主流
  - 2006 Hinton 深度信念网络，深度学习复兴
  - 2012 AlexNet 获 ImageNet 冠军，深度学习全面爆发
  - 2014 GAN、VAE 提出，生成模型兴起
  - 2015 ResNet（152 层）；DQN 实现端到端游戏智能
  - 2016 AlphaGo 击败李世石
  - 2017 Transformer（《Attention Is All You Need》）
  - 2018 BERT、GPT-1，预训练-微调范式确立
  - 2020 GPT-3（1750 亿参数）；RAG 提出
  - 2021 LoRA、ViT 成熟、扩散模型主导图像生成
  - 2022 ChatGPT、InstructGPT（RLHF 对齐）
  - 2023 GPT-4、Llama 2、MoE 架构普及
  - 2024 长上下文、多模态统一、推理增强（o1 类思维链）
  - 规律：每次跃迁由「算力 × 数据 × 算法」三者同时突破驱动
- 4. 学科分支全景
  - 基础方法：机器学习、深度学习、强化学习、优化理论
  - 感知方向：计算机视觉、语音识别与合成、多模态感知
  - 认知方向：自然语言处理、知识工程、推理与规划
  - 决策方向：强化学习、多智能体、机器人学、具身智能
  - 支撑方向：可解释 AI、AI 安全与对齐、AI 伦理与治理、AI 系统（编译器与芯片）
- 5. 与其他学科的关系
  - 数学：线性代数、概率统计、微积分、最优化、信息论
  - 统计学：统计学习理论、假设检验、贝叶斯推断
  - 计算机科学：算法、数据结构、分布式系统、编译
  - 认知科学：神经科学、心理学，提供建模范式启发
  - 控制论：反馈、稳定性、最优控制，支撑强化学习与机器人

二、方法与模型体系

- 1. 传统机器学习（Classical Machine Learning）
  - 1.1 监督学习（Supervised Learning）
    - 线性模型
      - 线性回归（Linear Regression）：最小二乘、正规方程、梯度下降
      - 正则化变体：Ridge（L2）、Lasso（L1，稀疏特征选择）、ElasticNet
      - 逻辑回归（Logistic Regression）：Sigmoid + 交叉熵，线性分类器
      - 广义线性模型（GLM）：指数族分布统一框架
    - 树模型
      - 决策树：ID3（信息增益）、C4.5（信息增益率）、CART（基尼系数）
      - 剪枝：预剪枝、后剪枝、代价复杂度剪枝
      - 随机森林（Random Forest，2001）：Bagging + 特征随机
      - GBDT（Gradient Boosting Decision Tree）：拟合负梯度
      - XGBoost（2016）：二阶泰勒展开 + 正则项 + 列采样
      - LightGBM（2017）：直方图算法 + Leaf-wise 生长
      - CatBoost（2017）：有序目标编码，抗类别特征偏差
    - 核方法与间隔模型
      - 支持向量机（SVM）：最大间隔、支持向量、对偶问题
      - 核技巧：线性核、多项式核、RBF 核、Sigmoid 核
      - 软间隔与惩罚系数 C；Hinge Loss
      - 相关向量机（RVM）：稀疏贝叶斯视角
    - 概率与判别模型
      - 朴素贝叶斯：条件独立假设、拉普拉斯平滑
      - 高斯判别分析（GDA）
      - 隐马尔可夫模型（HMM）：观测独立假设、Viterbi 解码
      - 条件随机场（CRF）：序列标注、全局归一化
      - 最大熵模型
    - 近邻与实例方法
      - K 近邻（KNN）：距离度量、K 值选择、维度灾难
      - 学习向量量化（LVQ）
    - 目标函数与优化
      - 经验风险最小化、结构风险最小化
      - 凸优化、梯度下降、坐标下降、SMO
      - 正则化：L1 稀疏、L2 平滑
    - 评估与选择
      - 偏差-方差分解（Bias-Variance Decomposition）
      - 过拟合与欠拟合的判别与对策
      - 交叉验证、留一法、分层抽样、时间序列切分
  - 1.2 无监督学习（Unsupervised Learning）
    - 聚类（Clustering）
      - K-means：欧氏距离、肘部法、轮廓系数、K-means++
      - 高斯混合模型（GMM）+ EM 算法：软聚类、概率归属
      - DBSCAN：密度可达、自动定簇、噪声识别
      - 层次聚类：AGNES、Ward 最小方差
      - 谱聚类（Spectral Clustering）：图割视角
      - 评价：轮廓系数、CH 指数、DB 指数、调整兰德指数
    - 降维（Dimensionality Reduction）
      - 主成分分析（PCA）：协方差特征值分解、SVD、方差解释率
      - 线性判别分析（LDA）：有监督降维，类间/类内散度比
      - t-SNE：KL 散度优化，局部结构保持，适合可视化
      - UMAP：流形学习，全局与局部平衡，速度优于 t-SNE
      - 非负矩阵分解（NMF）
      - 流形学习：Isomap、LLE、LE
    - 关联规则（Association Rules）
      - Apriori、FP-Growth
      - 指标：支持度（Support）、置信度（Confidence）、提升度（Lift）
    - 密度估计与异常检测
      - 核密度估计（KDE）
      - 孤立森林（Isolation Forest）：随机切分、路径长度
      - One-Class SVM、局部异常因子（LOF）
      - 自编码器重构误差法
  - 1.3 其他学习范式
    - 半监督学习（Semi-Supervised）：伪标签、协同训练、图半监督、一致性正则
    - 主动学习（Active Learning）：不确定性采样、委员会查询、期望误差降低
    - 迁移学习（Transfer Learning）：微调、特征提取、领域自适应、领域泛化
    - 多任务学习（Multi-Task）：硬共享、软共享、梯度冲突处理
    - 元学习（Meta-Learning）：MAML、Reptile、Prototypical Networks
    - 少样本 / 零样本学习（Few-Shot / Zero-Shot）
  - 1.4 集成学习（Ensemble Learning）
    - Bagging：自助采样、并行训练、降方差（随机森林）
    - Boosting：串行纠错、降偏差（AdaBoost、GBDT 系）
    - Stacking：元学习器融合基学习器输出
    - 多样性来源：样本扰动、特征扰动、算法扰动、超参扰动
- 2. 深度学习（Deep Learning）
  - 2.1 基础组件
    - 神经元与层
      - 计算：$y = f(\Sigma w_i x_i + b)$
      - 层类型：输入层、隐藏层、输出层；深度 = 隐藏层层数
      - 参数初始化：Xavier、He（Kaiming）、正交初始化
    - 激活函数（Activation）
      - Sigmoid：输出 (0,1)，两端饱和导致梯度消失
      - Tanh：零中心，仍有饱和问题
      - ReLU：max(0,x)，缓解梯度消失、产生稀疏，存在神经元死亡
      - LeakyReLU / PReLU / ELU：负半轴非零
      - GELU / SiLU（Swish）：Transformer 与大模型主流
      - Softmax：多分类归一化输出
    - 损失函数（Loss）
      - 回归：MSE、MAE、Huber、Log-Cosh
      - 分类：交叉熵（CE）、二分类交叉熵（BCE）、Focal Loss（类别不平衡）
      - 度量学习：Triplet Loss、Contrastive Loss、ArcFace、CosFace
      - 对比学习：InfoNCE、NT-Xent
      - 序列：CTC、Seq2Seq 交叉熵
      - 生成：对抗损失、重构损失、扩散噪声预测 MSE、ELBO
    - 反向传播（Backpropagation）
      - 链式法则、计算图、拓扑排序
      - 自动微分：前向模式、反向模式（PyTorch autograd）
      - 梯度消失与爆炸：成因与缓解（残差、归一化、门控、梯度裁剪）
    - 优化器（Optimizer）
      - 一阶：SGD、Momentum、Nesterov Accelerated Gradient
      - 自适应：AdaGrad、RMSProp、Adam、AdamW（解耦权重衰减）
      - 二阶近似：L-BFGS（小规模）、K-FAC
      - 超参：学习率、动量、β_1/β_2、ε、weight decay
    - 学习率调度（LR Schedule）
      - Step Decay、Exponential Decay、Cosine Annealing
      - Warmup（线性/余弦）、OneCycle、ReduceLROnPlateau
    - 正则化与归一化
      - L1 / L2 权重衰减、Max-Norm
      - Dropout、Spatial Dropout、DropPath（Stochastic Depth）
      - BatchNorm（批统计，CNN 常用）、LayerNorm（样本统计，Transformer 常用）
      - GroupNorm、InstanceNorm、RMSNorm
      - 标签平滑（Label Smoothing）、MixUp、CutMix、Cutout
      - 早停（Early Stopping）、模型平均（EMA / SWA）
  - 2.2 网络架构（Architectures）
    - 多层感知机（MLP）
      - 全连接层堆叠；万能近似定理（Universal Approximation）
      - 用途：表格数据、分类头、嵌入映射
    - 卷积神经网络（CNN）
      - 核心算子：卷积、池化（Max/Avg）、步长、填充、膨胀
      - 关键性质：局部连接、权值共享、平移等变、感受野逐层扩大
      - 经典演进：LeNet-5（1998）→ AlexNet（2012）→ VGG（2014）→ GoogLeNet/Inception（2014）→ ResNet（2015，残差）→ DenseNet（2017）→ SENet（2017，通道注意力）→ EfficientNet（2019，复合缩放）→ ConvNeXt（2022，现代化 CNN）
      - 变体：1D CNN（时序/语音）、3D CNN（视频）、空洞卷积（分割）、可变形卷积（DCN）、深度可分离卷积（MobileNet）
      - 典型任务：分类、检测、分割、超分、人脸识别
    - 循环神经网络（RNN）
      - 基本 RNN：隐状态递归、参数共享、BPTT
      - 门控结构：LSTM（输入/遗忘/输出门 + 细胞状态）、GRU（更新/重置门）
      - 变体：BiRNN、Deep RNN、Clockwork RNN
      - 序列到序列（Seq2Seq）+ 注意力机制
      - 现状：NLP 主干已被 Transformer 取代；时序预测、流式语音仍有应用
    - Transformer
      - 自注意力（Self-Attention）：Q/K/V、缩放点积 $\mathrm{softmax}(QK^T/\sqrt{d})V$
      - 多头注意力（Multi-Head）：多子空间并行、拼接投影
      - 位置编码：正弦式、可学习式、相对位置、RoPE（旋转）、ALiBi
      - 结构组件：残差连接、LayerNorm（Pre-LN/Post-LN）、FFN、MoE 稀疏专家
      - 三大变体：Encoder-only（BERT）、Decoder-only（GPT）、Encoder-Decoder（T5、原始 Transformer）
      - 视觉扩展：ViT（patch 化）、Swin（滑动窗口 + 层级）、DETR（集合预测）、DiT（扩散 Transformer）
      - 效率优化：FlashAttention、稀疏注意力、线性注意力、KV Cache、GQA/MQA
    - 图神经网络（GNN）
      - 消息传递框架（Message Passing）：聚合 + 更新
      - 代表：GCN（谱域一阶近似）、GAT（注意力权重）、GraphSAGE（采样聚合）、GIN（表达力上界）
      - 任务：节点分类、链路预测、图分类、图生成
      - 应用：分子性质预测、社交网络、推荐、知识图谱补全
    - 生成模型（Generative Models）
      - 自编码器（AE）、去噪自编码器（DAE）、稀疏自编码器
      - 变分自编码器（VAE）：隐变量、重参数化、ELBO、KL 正则
      - 生成对抗网络（GAN）：生成器/判别器博弈、Wasserstein GAN、StyleGAN、CycleGAN；问题：模式崩溃、训练不稳定
      - 扩散模型（Diffusion）：前向加噪马尔可夫链、反向去噪、DDPM、DDIM（加速）、Score-based、Latent Diffusion（Stable Diffusion）
      - 归一化流（Normalizing Flow）：可逆变换、精确似然
      - 自回归生成：PixelCNN、WaveNet、GPT 式逐 token 生成
    - 能量模型与图模型
      - 玻尔兹曼机、受限玻尔兹曼机（RBM）、深度信念网络（DBN）
      - 马尔可夫随机场、因子图、信念传播
  - 2.3 大模型与基础模型（Foundation Models）
    - 规模定律（Scaling Law）
      - 参数、数据、算力三者幂律关系；Chinchilla 最优配比
      - 涌现能力（Emergent Abilities）与相变现象
    - 训练范式
      - 预训练（Pretrain）：自监督目标（因果语言建模、掩码语言建模）
      - 监督微调（SFT）：指令数据、对话数据
      - 对齐（Alignment）：RLHF（PPO）、DPO、KTO、宪法 AI
    - 参数高效微调（PEFT）
      - LoRA（低秩分解）、QLoRA（量化 + LoRA）
      - Adapter、Prefix Tuning、Prompt Tuning、IA^3
    - 推理增强
      - 思维链（CoT）、自洽性（Self-Consistency）、思维树（ToT）
      - 工具调用（Function Calling）、ReAct、Agent 框架
    - 检索增强生成（RAG）
      - 向量检索、混合检索、重排（Rerank）、上下文压缩
      - 幻觉抑制、引用溯源
    - 多模态大模型
      - 图文对齐：CLIP、ALIGN、SigLIP
      - 视觉-语言模型：BLIP-2、LLaVA、Qwen-VL、InternVL、GPT-4V
      - 视频与音频：Video-LLaVA、Whisper、AudioLM
    - 代表模型
      - 国外：GPT 系列、Claude、Gemini、Llama 系列、Mistral
      - 国内：Qwen、DeepSeek、GLM、Baichuan、MiniMax、Kimi
    - 关键工程
      - 分布式训练：DDP、FSDP、ZeRO、Megatron-LM、DeepSpeed、流水线并行
      - 显存优化：混合精度（AMP/BF16）、梯度累积、梯度检查点、Offload
      - 推理加速：量化（INT8/INT4/GPTQ/AWQ）、KV Cache、投机解码、vLLM、TensorRT-LLM
  - 2.4 强化学习（Reinforcement Learning）
    - 形式化
      - 马尔可夫决策过程（MDP）：状态 S、动作 A、转移 P、奖励 R、折扣 γ
      - 策略 π、价值函数 V、动作价值 Q、优势函数 A
      - 贝尔曼方程、贝尔曼最优方程
    - 无模型方法
      - 基于价值：Q-Learning、SARSA、DQN（经验回放 + 目标网络）、Double DQN、Dueling DQN、Rainbow
      - 基于策略：REINFORCE、Actor-Critic、A2C/A3C、PPO、TRPO、SAC、DDPG、TD3
    - 有模型方法
      - 动态规划：策略迭代、价值迭代
      - 蒙特卡洛树搜索（MCTS）：AlphaGo/AlphaZero
      - 世界模型（World Model）、Dreamer
    - 其他分支
      - 模仿学习（Imitation Learning）、逆强化学习（IRL）
      - 离线强化学习（Offline RL）、多智能体强化学习（MARL）
      - 分层强化学习（HRL）
    - 应用：游戏、机器人控制、推荐、资源调度、RLHF 对齐
- 3. 学习范式分类（按监督信号）
  - 监督学习（Supervised）：全标注数据
  - 无监督学习（Unsupervised）：无标注，学数据结构
  - 自监督学习（Self-Supervised）：从数据本身构造代理任务
    - 对比式：SimCLR、MoCo、BYOL、SimSiam
    - 生成式/掩码式：MAE、BEiT、BERT、SimMIM
  - 半监督学习（Semi-Supervised）：少量标注 + 大量无标注
  - 弱监督学习（Weakly-Supervised）：粗粒度标注（图像级、点、框）
  - 强化学习（Reinforcement）：延迟奖励、序贯决策
  - 迁移 / 多任务 / 元学习：跨任务知识复用
- 4. 任务类型（Task Taxonomy）
  - 判别式任务
    - 分类（Classification）、回归（Regression）、排序（Ranking）
    - 检测（Detection）、分割（Segmentation）、关键点（Keypoint）
    - 检索与匹配（Retrieval）、度量学习（Metric Learning）
  - 生成式任务
    - 文本生成、图像生成、语音合成、视频生成、3D 生成
    - 序列到序列（翻译、摘要、对话）
  - 结构学习任务
    - 聚类、降维、异常检测、密度估计
    - 图任务：节点分类、链路预测、图生成
  - 决策类任务
    - 序贯决策、规划、多智能体协同
- 5. 数据类型与方法映射
  - 表格 / 结构化数据：树模型（XGBoost / LightGBM）、线性模型、MLP
  - 图像：CNN、ViT、扩散模型
  - 视频：3D CNN、时空 Transformer、光流网络
  - 文本：Transformer（BERT / GPT）、Embedding 检索
  - 语音：CNN + RNN、Conformer、Whisper
  - 图 / 关系数据：GNN、图嵌入（Node2Vec、DeepWalk）
  - 时序：RNN、TCN、Transformer、传统统计模型（ARIMA、Prophet）
  - 多模态：CLIP 式对比学习、跨模态注意力、统一 token 化
- 6. 工具、框架与基础设施
  - 数学基础
    - 线性代数：矩阵运算、特征值分解、SVD、秩、范数
    - 概率统计：条件概率、贝叶斯、常见分布、MLE/MAP、假设检验
    - 微积分：偏导、梯度、雅可比、海森、链式法则
    - 最优化：凸优化、梯度下降族、拉格朗日乘子、KKT
    - 信息论：熵、交叉熵、KL 散度、互信息
  - 编程与科学计算
    - Python：语法、类、装饰器、生成器、异步
    - NumPy（广播与向量化）、Pandas、Matplotlib / Seaborn
    - C++ / CUDA：算子开发与性能优化
  - 深度学习框架
    - PyTorch：动态图、生态最全，研究与工业首选
    - TensorFlow / Keras：静态图与部署链路成熟
    - JAX：函数式、jit 编译、高性能研究
    - PaddlePaddle、MindSpore：国产框架与信创适配
  - 领域库与工具链
    - 经典 ML：scikit-learn、XGBoost、LightGBM、CatBoost
    - 视觉：timm、MMLab 系列、Detectron2、Ultralytics
    - NLP / 大模型：Hugging Face Transformers、PEFT、vLLM、LangChain、LlamaIndex
    - 强化学习：Gymnasium、Stable-Baselines3、Ray RLlib
    - 图：PyG、DGL
  - 工程基础设施
    - 实验管理：W&B、MLflow、TensorBoard
    - 版本与复现：Git、DVC、Hydra 配置管理
    - 运行环境：Docker、Kubernetes、CUDA/cuDNN、分布式存储

三、数据与评估

- 1. 数据形态与标注类型
  - 数据形态：表格、图像、视频、文本、语音、图、时序、多模态
  - 标注类型
    - 分类标签、回归目标、边界框、像素掩码、关键点
    - 序列标注、关系三元组、偏好排序（RLHF）
  - 标注成本与质量：众包标注、专家标注、弱标注、半自动标注
- 2. 常用数据集
  - 经典机器学习
    - UCI Machine Learning Repository（Iris、Wine、Adult）
    - Kaggle 竞赛数据集（表格类为主）
  - 计算机视觉
    - MNIST、CIFAR-10/100、ImageNet-1K（1000 类）
    - COCO（检测/分割/关键点）、PASCAL VOC、ADE20K
    - Kinetics（视频动作）、Cityscapes（自动驾驶分割）
  - 自然语言处理
    - GLUE / SuperGLUE（NLU 基准）、SQuAD（阅读理解）
    - MS MARCO（检索）、WMT（机器翻译）、WikiText（语言建模）
    - CLUE / C-Eval / CMMLU（中文基准）
  - 语音
    - LibriSpeech（ASR）、VCTK（TTS）、AudioSet（音频事件）
  - 图与推荐
    - Cora / CiteSeer / PubMed（引文网络）、OGB（开放图基准）
    - MovieLens、Amazon Reviews（推荐）
  - 大模型评测
    - MMLU（57 学科知识）、GSM8K（数学推理）、HumanEval（代码）
    - MT-Bench、AlpacaEval（对话质量）、HELM（综合评测）
- 3. 数据工程
  - 数据获取：公开数据集、爬取、业务日志、合成生成
  - 数据清洗：缺失值、异常值、重复项、噪声标签
  - 数据增强
    - 图像：翻转、裁剪、颜色抖动、MixUp、CutMix、RandAugment
    - 文本：回译、同义替换、随机删除、EDA
    - 语音：加噪、变速、SpecAugment
  - 数据配比与课程学习（Curriculum Learning）
  - 数据泄漏识别：时序泄漏、目标泄漏、训练测试同源
  - 隐私与合规：脱敏、差分隐私、联邦学习
- 4. 评估指标
  - 分类
    - 混淆矩阵（TP/FP/TN/FN）
    - Accuracy、Precision、Recall、F1-score
    - ROC-AUC、PR-AUC、Cohen's Kappa
  - 回归
    - MSE、RMSE、MAE、MAPE、R^2、分位数损失
  - 排序与推荐
    - NDCG、MAP、MRR、Hit Rate、AUC
  - 检测与分割
    - IoU、mAP@0.5、mAP@0.5:0.95、mIoU、Dice
  - 生成
    - 文本：BLEU、ROUGE、METEOR、CIDEr、困惑度（PPL）
    - 图像：FID、IS、LPIPS、CLIPScore
    - 语音：MOS、WER、CER
  - 检索与嵌入
    - Recall@K、Precision@K、mAP、MRR
  - 强化学习
    - 累积回报（Return）、样本效率、成功率、探索覆盖率
  - 大模型
    - 准确率（MMLU/GSM8K/HumanEval）、胜率（Arena Elo）、忠实度与幻觉率
- 5. 评估方法与统计
  - 数据划分：训练/验证/测试、K 折交叉验证、留一法、分层抽样
  - 时间序列：滚动窗口、前向验证，严禁随机打乱
  - 偏差-方差权衡：学习曲线、验证曲线诊断
  - 统计严谨性：置信区间、显著性检验、多随机种子
  - 常见陷阱
    - 测试集泄漏、指标选择与业务目标错位
    - 单次实验结果当作结论、忽略方差
- 6. 基准与竞赛
  - 学术榜单：Papers with Code、GLUE、ImageNet、COCO、OGB
  - 竞赛平台：Kaggle、天池、DataCastle、Codalab
  - 大模型评测：Open LLM Leaderboard、C-Eval、SuperCLUE、LMSYS Arena

四、应用领域

- 1. 计算机视觉
  - 任务：分类、检测、分割、跟踪、三维重建、生成
  - 落地：安防、工业质检、自动驾驶、医疗影像、遥感
  - 代表：ResNet、YOLO 系列、SAM、Stable Diffusion
- 2. 自然语言处理
  - 任务：分类、抽取、翻译、摘要、问答、对话、代码生成
  - 落地：搜索、客服、文档处理、编程助手
  - 代表：BERT、GPT 系列、T5、LLaMA
- 3. 语音
  - 任务：语音识别（ASR）、语音合成（TTS）、声纹识别、语音增强
  - 代表：Whisper、Conformer、Tacotron、VITS
- 4. 推荐与广告
  - 任务：召回、粗排、精排、重排、CTR/CVR 预估
  - 方法：协同过滤、双塔模型、DIN、DeepFM、图推荐
  - 特点：特征工程 + 实时性要求高
- 5. 搜索与信息检索
  - 任务：查询理解、召回、排序、生成式检索
  - 方法：BM25、稠密检索（DPR）、重排（Cross-Encoder）
- 6. 金融与风控
  - 任务：信用评分、反欺诈、量化交易、文档审核
  - 特点：强可解释、强合规、样本不平衡
- 7. 医疗健康
  - 任务：影像诊断、病理分析、药物发现、病历结构化
  - 代表：AlphaFold（蛋白质结构）、nnU-Net（医学分割）
  - 挑战：标注昂贵、可解释性、法规审批
- 8. 自动驾驶与机器人
  - 任务：感知、预测、规划、控制
  - 方法：BEV 感知、端到端驾驶（UniAD）、模仿学习、强化学习
  - 代表：Tesla FSD、Waymo、RT-2（视觉-语言-动作）
- 9. 工业与制造
  - 任务：缺陷检测、预测性维护、工艺优化、排产调度
  - 特点：小样本、少缺陷、边缘部署
- 10. 科学与工程
  - 任务：分子生成、材料筛选、气象预报、流体仿真
  - 代表：AlphaFold、GraphCast、AI for Science
- 11. AIGC 与内容生产
  - 任务：文生图、文生视频、数字人、音乐生成、代码生成
  - 代表：Stable Diffusion、Sora、Suno、GitHub Copilot
- 12. 教育与政务
  - 任务：智能批改、个性化推荐、政策问答、文档审查

五、工程实践与能力路径

- 1. 训练与工程实践
  - 训练流程：数据准备 → 基线模型 → 迭代调优 → 消融实验 → 压缩导出
  - 分布式训练：DDP、FSDP、ZeRO、张量并行、流水线并行
  - 显存与吞吐优化：AMP、梯度累积、梯度检查点、重计算、Offload
  - 训练稳定性：梯度裁剪、loss scaling、warmup、监控 NaN
  - 推理部署
    - 图优化：算子融合、常量折叠、动态 shape
    - 压缩：量化（PTQ/QAT）、蒸馏、剪枝、低秩分解
    - 引擎：ONNX Runtime、TensorRT、OpenVINO、vLLM、llama.cpp
  - 实验管理：配置化（Hydra）、版本化（Git + DVC）、可复现（固定种子）
  - 常见失败模式
    - 过拟合 / 欠拟合、数据泄漏、分布偏移
    - 指标虚高（测试集污染）、离线在线不一致
    - 长尾类别性能塌陷、部署精度掉点
- 2. 能力模型（算法工程师）
  - 数学与理论：能读懂论文公式、能推导损失与梯度
  - 编程与工程：Python 熟练、能写可维护的训练/推理代码
  - 数据处理：清洗、特征、标注质量管理
  - 实验能力：设计消融、定位问题、复现他人结果
  - 系统能力：性能分析、显存/延迟优化、服务化
  - 表达与写作：技术文档、论文撰写、答辩
- 3. 阶段化学习路径
  - 阶段 0：基础（1–2 个月）
    - Python、NumPy/Pandas、线性代数、概率统计
    - 验收：能手写矩阵运算、能读懂梯度公式
  - 阶段 1：传统机器学习（2 个月）
    - 内容：线性/逻辑回归、树模型、SVM、聚类、降维、评估体系
    - 实践：scikit-learn 完成端到端项目
    - 验收：独立完成表格数据建模并解释每一步选择
  - 阶段 2：深度学习基础（2–3 个月）
    - 内容：反向传播、优化器、CNN、RNN、Transformer
    - 实践：PyTorch 实现 MLP/CNN/小型 Transformer
    - 验收：能从 loss 曲线定位问题并给出对策
  - 阶段 3：方向深入（3 个月以上）
    - 计算机视觉 / NLP 与大模型 / 推荐与搜索 / 多模态与具身
    - 验收：复现一篇顶会论文 + 完成一个可演示项目
  - 阶段 4：工程化与输出
    - 部署、实验管理、竞赛、开源、实习、论文
- 4. 学习资源
  - 课程：吴恩达 Machine Learning / Deep Learning、李沐《动手学深度学习》、CS231n、CS224n
  - 教材：《统计学习方法》（李航）、《机器学习》（周志华）、《深度学习》（Goodfellow）
  - 实践：Kaggle、Hugging Face、Papers with Code、开源复现仓库
- 5. 常见认知偏差（FAQ）
  - 「神经网络 = 深度学习」：不等价，前者是结构层，后者是方法层
  - 「机器学习 = 深度学习」：包含关系，DL ⊂ ML
  - 「人工智能 = 机器学习」：AI 还包含符号推理、搜索与规划
  - 「大模型是新技术路线」：本质仍是深度学习 + Transformer + 自监督预训练
  - 「传统机器学习已过时」：表格数据、小样本、强可解释场景仍为主力
  - 「必须配齐显卡才能入门」：入门阶段免费算力足够，规模化训练才需自建集群
  - 「跳过基础直接学大模型」：缺少反向传播与评估体系，问题无法定位
  - 「调参靠玄学」：本质是对偏差方差与数据分布理解不足

Presented with xmind